ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ

ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ — ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ Η/Υ & ΠΛΗΡΟΦΟΡΙΚΗΣ

Αρχιτεκτονικές Δικτύων Επόμενης Γενιάς,
Τεχνολογίες και Εφαρμογές

Θέμα Project #13

Clustering και Χαρακτηρισμός Clusters σε Χωρική και Χρονική Δραστηριότητα 5G

Εκπονήθηκε από:

Λεωνίδας Γκουρβέλος 1072506

Γιώργος Λαλάς 1093406

Επιβλέπων – Σύμβουλος:
Νίκος Ράπτης (nraptis@isi.gr)

Εαρινό Εξάμηνο 2026

1. Εισαγωγή

Η συνεχής αύξηση της κίνησης δεδομένων στα σύγχρονα δίκτυα 5G και 6G δημιουργεί την ανάγκη για καλύτερη κατανόηση του τρόπου με τον οποίο οι χρήστες αξιοποιούν το δίκτυο σε διαφορετικές περιοχές και χρονικές περιόδους. Η ανάλυση χωρικών και χρονικών μοτίβων δραστηριότητας μπορεί να βοηθήσει σημαντικά στη διαχείριση πόρων, στη βελτίωση της ποιότητας υπηρεσιών (QoS) και στον αποδοτικότερο σχεδιασμό των υποδομών ενός τηλεπικοινωνιακού δικτύου.

Στην παρούσα εργασία μελετώνται δεδομένα τηλεπικοινωνιακής δραστηριότητας από την πόλη του Μιλάνου με χρήση τεχνικών clustering. Μέσω αλγορίθμων μη επιβλεπόμενης μάθησης επιχειρείται η ομαδοποίηση περιοχών με παρόμοια χαρακτηριστικά χρήσης, ώστε να εντοπιστούν διαφορετικά πρότυπα δικτυακής συμπεριφοράς.

Για την ανάλυση χρησιμοποιήθηκε το Milan Telecom Dataset (Harvard Dataverse), το οποίο περιλαμβάνει δεδομένα εισερχόμενων και εξερχόμενων SMS, τηλεφωνικών κλήσεων και χρήσης διαδικτύου. Τα δεδομένα είναι οργανωμένα σε πλέγμα 100×100 grid-cells που καλύπτει την περιοχή του Μιλάνου και αφορούν χρονικό διάστημα περίπου δύο μηνών.

Στόχος Εργασίας

Στόχος της εργασίας είναι η εφαρμογή τεχνικών clustering για την ανάλυση χωρικών και χρονικών προτύπων δραστηριότητας σε δεδομένα τηλεπικοινωνιακής κίνησης. Μέσω αλγορίθμων όπως οι K-Means και Hierarchical Clustering επιχειρείται η ομαδοποίηση περιοχών με παρόμοια χαρακτηριστικά χρήσης δικτύου και η μελέτη της συμπεριφοράς τους ως προς τη συνολική δραστηριότητα, τη χρονική κατανομή και τη χρήση υπηρεσιών.

Παράλληλα, γίνεται αξιολόγηση της ποιότητας των clusters με χρήση κατάλληλων μετρικών, ώστε να εξεταστεί η αποτελεσματικότητα των μεθόδων clustering στην ανάλυση δεδομένων δικτύων 5G/6G.

2. Θεωρητικό Μέρος

2.1 Clustering στις Τηλεπικοινωνίες

Η συσταδοποίηση (clustering) αποτελεί μια σημαντική τεχνική μη επιβλεπόμενης μάθησης (unsupervised learning), που στοχεύει στην ομαδοποίηση δεδομένων βάσει ομοιότητας, χωρίς εκ των προτέρων γνωστές ετικέτες. Στα δίκτυα 5G, η συσταδοποίηση επιτρέπει:

- Εντοπισμό περιοχών με παρόμοια πρότυπα χρήσης δικτύου
- Δυναμική κατανομή πόρων ανάλογα με τη ζήτηση
- Προσαρμογή στρατηγικών δικτύου για διαφορετικά τμήματα της πόλης
- Βελτίωση κάλυψης σε περιοχές υψηλής χρήσης
- Πρόβλεψη συμφόρησης δικτύου σε συγκεκριμένες περιοχές και ώρες

2.2 Μελέτη Τεχνικών Clustering

K-Means Clustering

Ο αλγόριθμος K-Means χωρίζει τα δεδομένα σε K clusters, προσπαθώντας να ελαχιστοποιήσει τη διακύμανση μέσα σε κάθε cluster (inertia). Σε κάθε επανάληψη, κάθε σημείο αντιστοιχίζεται στο κοντινότερο centroid και στη συνέχεια τα centroids ενημερώνονται με βάση τα νέα δεδομένα.

Ο K-Means είναι υπολογιστικά αποδοτικός και μπορεί να εφαρμοστεί εύκολα σε μεγάλα datasets, ενώ τα αποτελέσματά του είναι σχετικά εύκολα στην ερμηνεία. Παρόλα αυτά, απαιτεί προκαθορισμό του αριθμού clusters (K), είναι ευαίσθητος στην αρχικοποίηση και επηρεάζεται από outliers και μη σφαιρικά clusters.

Hierarchical Clustering (Ward Linkage)

Το Hierarchical Clustering με Ward linkage δημιουργεί ιεραρχική δομή clusters συγχωνεύοντας επαναληπτικά τις ομάδες που προκαλούν τη μικρότερη αύξηση της εντός-cluster διακύμανσης. Το αποτέλεσμα παρουσιάζεται συνήθως με τη μορφή δενδρογράμματος (dendrogram).

Η μέθοδος δεν απαιτεί αρχικά τον ορισμό του αριθμού clusters και επιτρέπει καλύτερη εποπτεία της ιεραρχικής σχέσης μεταξύ τους. Ωστόσο, έχει μεγαλύτερο υπολογιστικό κόστος σε σχέση με τον K-Means και δεν είναι ιδιαίτερα αποδοτική σε πολύ μεγάλα datasets.

2.3 Σχεδιασμός Δικτύου 5G/6G βάσει Clusters

Η γνώση των clusters δραστηριότητας μπορεί να αξιοποιηθεί άμεσα στο σχεδιασμό δικτύων επόμενης γενιάς:

- Δυναμική κατανομή πόρων: Κατανομή bandwidth και φασματικών πόρων ανάλογα με το cluster κάθε super-cell
- Network Slicing: Δημιουργία εξειδικευμένων slices για αστικές (eMBB), βιομηχανικές (URLLC) και IoT (mMTC) περιοχές
- Προσαρμοστική τοποθέτηση κεραιών: Εντατικοποίηση κάλυψης σε περιοχές Cluster 4
- Ενεργειακή αποδοτικότητα: Μείωση ισχύος εκπομπής σε αδρανείς περιοχές (Cluster 0/1) κατά τις νυχτερινές ώρες
- Πρόβλεψη ζήτησης: Χρονικά μοτίβα ανά cluster για proactive resource management

3. Υλοποίηση

3.1 Ανάλυση Dataset και Επιλογή Χαρακτηριστικών

Το Milan Telecom Dataset περιέχει πέντε μετρούμενες ποσότητες ανά κελί και χρονική σήμανση: sms_in, sms_out, call_in, call_out και internet, από τις οποίες παράγεται και η συνολική δραστηριότητα (total_activity) ως άθροισμά τους.

Τα χαρακτηριστικά που χρησιμοποιούνται στο clustering οργανώνονται σε τρεις κατηγορίες:

Χαρακτηριστικά έντασης δραστηριότητας (mean_total, std_total, peak_total_act, mean ανά υπηρεσία, internet_share, cv_total): αποτυπώνουν πόσο «φορτωμένη» είναι κάθε περιοχή κατά μέσο όρο, στις κορυφές της και ως προς τη σύνθεση των υπηρεσιών. Αναμένεται να είναι τα πιο διαχωριστικά features, καθώς η κίνηση διαφέρει δραματικά μεταξύ εμπορικού κέντρου και περιφέρειας. Το cv_total συμπληρώνει την εικόνα ανιχνεύοντας περιοχές με σποραδική ή ανομοιόμορφη χρήση, ανεξάρτητα από το απόλυτο επίπεδο δραστηριότητας.

Χαρακτηριστικά χρονικής κατανομής (rush_ratio, night_ratio, weekend_ratio, peak_rush_mean, peak_night_mean, peak_weekend_mean): εκφράζουν πότε συγκεντρώνεται η δραστηριότητα κάθε περιοχής. Είναι κρίσιμα για τη διάκριση εμπορικών ζωνών (αιχμή εργάσιμων ωρών 7–9, 17–19) από κατοικημένες (αυξημένη νυχτερινή και weekend παρουσία) ή περιοχές με μικτό χαρακτήρα. Δύο περιοχές με παρόμοιο συνολικό επίπεδο κίνησης μπορούν να διαχωριστούν σε διαφορετικά clusters αποκλειστικά μέσω αυτών των features.

Χωρικά χαρακτηριστικά (αυτά αναφέρονται καθώς χρησιμοποιήθηκαν στο κεφάλαιο 8 όπου έγινε επέκταση του κώδικα) (dist_horizontal, dist_vertical, dist_diagonal): εκφράζουν την απόσταση κάθε super-cell από το κέντρο του grid στον οριζόντιο, κατακόρυφο και Manhattan (διαγώνιο) άξονα αντίστοιχα. Εισάγουν ρητά τη γεωγραφική πληροφορία στο feature space, ώστε οι αλγόριθμοι να διαχωρίζουν κεντρικές από περιφερειακές περιοχές ακόμα και όταν τα υπόλοιπα χαρακτηριστικά είναι παρόμοια. Το dist_diagonal ως Manhattan απόσταση συνδυάζει οριζόντιο και κατακόρυφο άξονα ισότιμα, χωρίς να αποκρύπτει τη διαφορά μεταξύ των δύο συνιστωσών όπως θα έκανε το Euclidean.

.

3.2 Προεπεξεργασία Δεδομένων

Η προεπεξεργασία των δεδομένων πραγματοποιήθηκε σε διαδοχικά στάδια με στόχο τη μείωση του όγκου των δεδομένων, τη δημιουργία κατάλληλων χαρακτηριστικών και τη βελτίωση της απόδοσης των αλγορίθμων clustering.

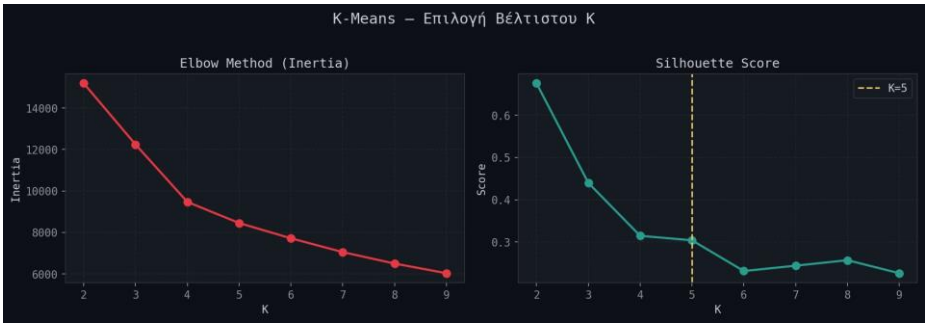
- **Aggregation ανά 10 δευτερόλεπτα:**
  Τα raw telecom δεδομένα ομαδοποιήθηκαν χρονικά ανά 10 δευτερόλεπτα ώστε να μειωθεί ο συνολικός όγκος δεδομένων και να επιταχυνθεί η επεξεργασία.
- **Ομαδοποίηση Grid Cells σε Super-Cells:**
  Τα grid cells συνδυάστηκαν σε μεγαλύτερες χωρικές μονάδες (super-cells), όπου κάθε 6 grid cells αντιστοιχούν σε 1 super-cell (τα οποία έχουν παρθεί σε μορφή 1x6 ξεκινώντας από πάνω αριστερά). Με τον τρόπο αυτό προέκυψαν περίπου 1.667 super-cells συνολικά, επιτρέποντας πιο αποδοτική χωρική ανάλυση.
- **Χειρισμός Missing Values:**
  Οι κενές τιμές συμπληρώθηκαν με τη διάμεσο (median) κάθε χαρακτηριστικού, ώστε να διατηρηθεί σταθερή η αναπαράσταση των δεδομένων και να μειωθεί η επίδραση ακραίων τιμών (outliers). (αν και δεν περιμένουμε να έχουμε missing values λόγο του aggregation και της δημιουργίας supercell).

- **Εξαγωγή Χαρακτηριστικών (Feature Extraction):**
  Δημιουργήθηκαν χαρακτηριστικά που περιγράφουν τη συνολική δραστηριότητα, τη μέση ωριαία και ημερήσια δραστηριότητα, τις αναλογίες δραστηριότητας σε ώρες αιχμής και νυχτερινές ώρες, καθώς και ο συντελεστής μεταβλητότητας (Coefficient of Variation – CV).
- **Φιλτράρισμα Ανενεργών Περιοχών:**
  Αφαιρέθηκαν super-cells με μηδενική ή ελάχιστη δραστηριότητα, τα οποία αντιστοιχούσαν κυρίως σε περιοχές εκτός του αστικού ιστού.
- **Κανονικοποίηση (Standardization):**
  Εφαρμόστηκε StandardScaler ώστε όλα τα χαρακτηριστικά να έχουν μέση τιμή 0 και τυπική απόκλιση 1. Η διαδικασία αυτή βελτίωσε την απόδοση των αλγορίθμων K-Means και Hierarchical Clustering, εξασφαλίζοντας ισορροπημένη συμβολή όλων των features.
- **Μείωση Διαστατικότητας με PCA:**
  Για την οπτικοποίηση των αποτελεσμάτων χρησιμοποιήθηκε Principal Component Analysis (PCA). Οι δύο πρώτες κύριες συνιστώσες εξηγούν συνολικά περίπου το 83.9% της συνολικής διακύμανσης των δεδομένων (68.1% και 15.8% αντίστοιχα).

3.3 Επιλογή Βέλτιστου K

Για την επιλογή του βέλτιστου αριθμού clusters χρησιμοποιήθηκαν δύο μέθοδοι:

- Elbow Method (Inertia): Παρατηρείται μείωση της κλίσης γύρω στο K=5 (Θα ήταν αποδεκτή και η επιλογή K=4 αλλά επιλέχθηκε K=5 για την καλύτερη ερμηνεία των αποτελεσμάτων)
- Silhouette Score: Μετά από K=2 (υψηλή τιμή λόγω πλήθους αδρανών super-cells), η καμπύλη σταθεροποιείται, με K=5 να αποδίδει ικανοποιητική ισορροπία (score ~0.30)



Σχήμα 1: Elbow Method (Inertia) και Silhouette Score για K=2..9. Η διακεκομμένη κίτρινη γραμμή υποδεικνύει το επιλεγμένο K=5.

Στο πλαίσιο του πειραματισμού δοκιμάστηκαν τιμές K από 2 έως 9. Το K=2 δίνει υψηλό Silhouette (~0.6) λόγω του μεγάλου πλήθους αδρανών super-cells που σχηματίζουν μια ξεκάθαρη ομάδα, χωρίς όμως να προσφέρει ερμηνεύσιμη διαφοροποίηση των περιοχών. Το K=4 θα ήταν αποδεκτή επιλογή βάσει του Elbow, αλλά επιλέχθηκε τελικά K=5 γιατί διαχωρίζει καθαρότερα την "Έντονη Αστική Ζώνη" (C3) από το "Εμπορικό Κέντρο" (C4), δίνοντας πιο ερμηνεύσιμα και χρήσιμα clusters για εφαρμογές 5G. Τιμές K≥6 δεν βελτίωσαν τις μετρικές και οδήγησαν σε πολύ μικρά clusters χωρίς σαφή χαρακτήρα.

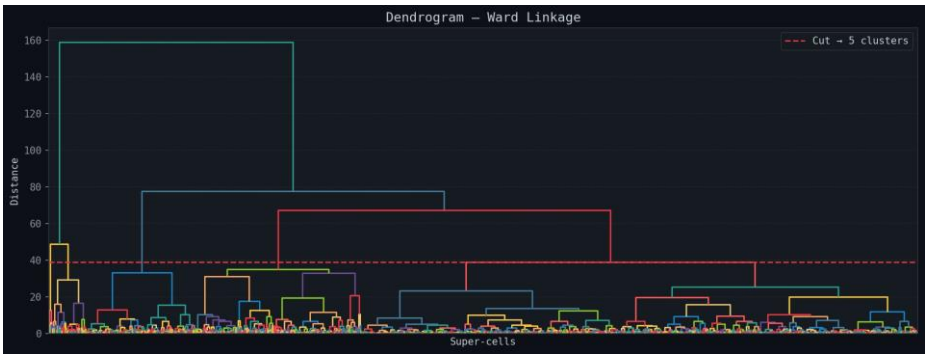
3.4 Εφαρμογή Αλγορίθμων Clustering

K-Means (K=5)

Ο K-Means εφαρμόστηκε με K=5 και πολλαπλές αρχικοποιήσεις (n_init=20) για αποφυγή τοπικών ελαχίστων. Το αποτέλεσμα ήταν 5 διακριτά clusters με αριθμό super-cells: C0: 844, C1: 508, C2: 206, C3: 82, C4: 27.

Hierarchical Clustering (Ward Linkage)

Ο ιεραρχικός αλγόριθμος με Ward linkage εφαρμόστηκε και το δενδρόγραμμα «κόπηκε» στο επίπεδο που αντιστοιχεί σε 5 clusters για να μπορέσει να γίνει μια δίκαιη σύγκριση μεταξύ των δυο αλγορίθμων. Τα αποτελέσματα είναι παρόμοια: C0: 1068, C1: 318, C2: 209, C3: 65, C4: 7.

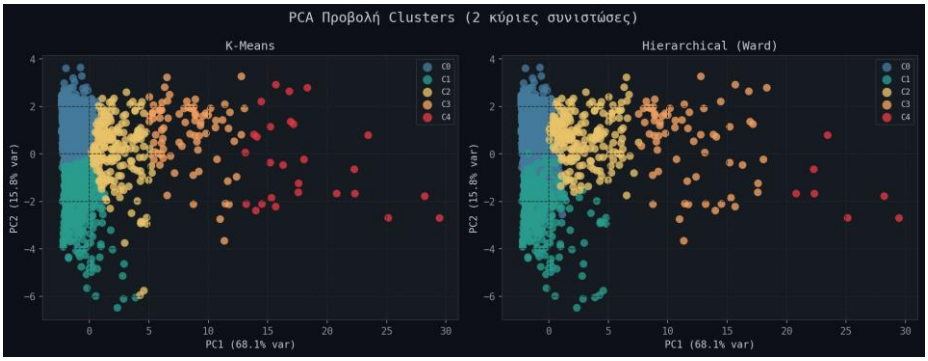


Σχήμα 2: Δενδρόγραμμα Ward Linkage. Η διακεκομμένη κόκκινη γραμμή υποδεικνύει το κόψιμο για 5 clusters.

3.5 PCA Οπτικοποίηση Clusters

Η προβολή PCA (2 κύριες συνιστώσες, συνολική διακύμανση 83.9%) χρησιμοποιήθηκε για την οπτικοποίηση και εποπτεία της διαχωρισιμότητας των clusters. Παρατηρείται ότι ο άξονας PC1 (68.1% της διακύμανσης) διαχωρίζει αρκετά καθαρά τα clusters ανάλογα με το επίπεδο συνολικής δραστηριότητας. Αντίθετα, στον άξονα PC2 (15.8%) εμφανίζεται μεγαλύτερη επικάλυψη μεταξύ clusters, γεγονός που υποδηλώνει ότι η δεύτερη συνιστώσα συμβάλλει λιγότερο στον διαχωρισμό τους.

Παρατηρείται επίσης ότι ο K-Means παρουσιάζει πιο καθαρό σχηματισμό clusters συγκριτικά με το Hierarchical Clustering.



Σχήμα 3: PCA Προβολή Clusters. Αριστερά K-Means, δεξιά Hierarchical (Ward). Ο κύριος διαχωρισμός πραγματοποιείται κατά μήκος του άξονα PC1.

3.6 Αξιολόγηση Μετρικών

Τρεις μετρικές αξιολόγησης χρησιμοποιήθηκαν για σύγκριση των δύο αλγορίθμων:

Μετρική	K-Means	Hierarchical (Ward)	Καλύτερο
Silhouette ↑	0.304	0.331	Hierarchical
Davies-Bouldin ↓	1.098	1.081	Hierarchical
Calinski-Harabasz ↑	977.482	860.190	K-Means

Silhouette Score

Μετρά το πόσο καλά διαχωρίζονται τα clusters μεταξύ τους και πόσο κοντά βρίσκονται τα σημεία στο cluster τους.
Τιμές κοντά στο 1 σημαίνουν πολύ καλό clustering, ενώ τιμές κοντά στο 0 δείχνουν επικάλυψη clusters.

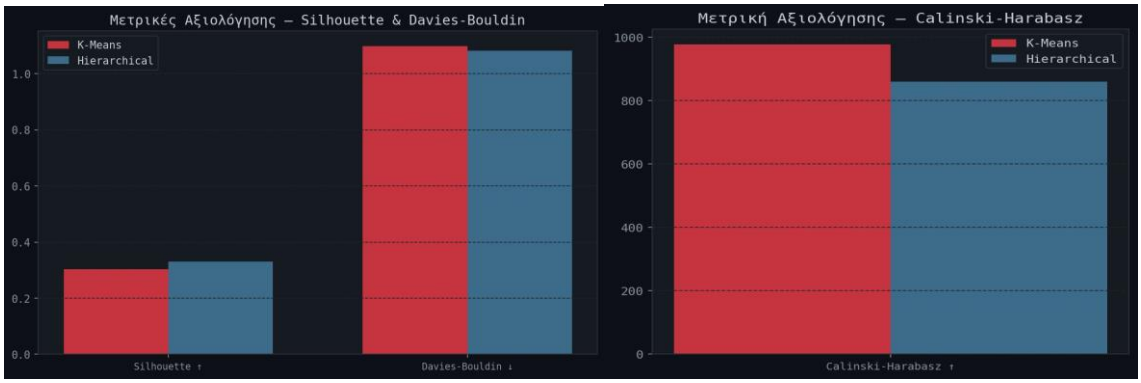
Davies–Bouldin Index

Αξιολογεί τη συνοχή των clusters και την απόστασή τους μεταξύ τους.
Όσο μικρότερη είναι η τιμή, τόσο καλύτερος θεωρείται ο διαχωρισμός των clusters.

Calinski–Harabasz Score

Μετρά τη σχέση μεταξύ της διασποράς μεταξύ clusters και της διασποράς μέσα στα clusters.
Μεγαλύτερες τιμές υποδηλώνουν καλύτερο διαχωρισμό και πιο συμπαγή clusters.

Ο Hierarchical αλγόριθμος υπερέχει στις Silhouette και Davies-Bouldin, υποδηλώνοντας καλύτερη εσωτερική συνοχή και διαχωρισιμότητα των clusters. Ο K-Means υπερέχει στο Calinski-Harabasz, που προτιμά compact clusters. Συνολικά, ο Hierarchical παράγει πιο «καθαρά» clusters και για αυτό το λόγο επιλέχθηκε.



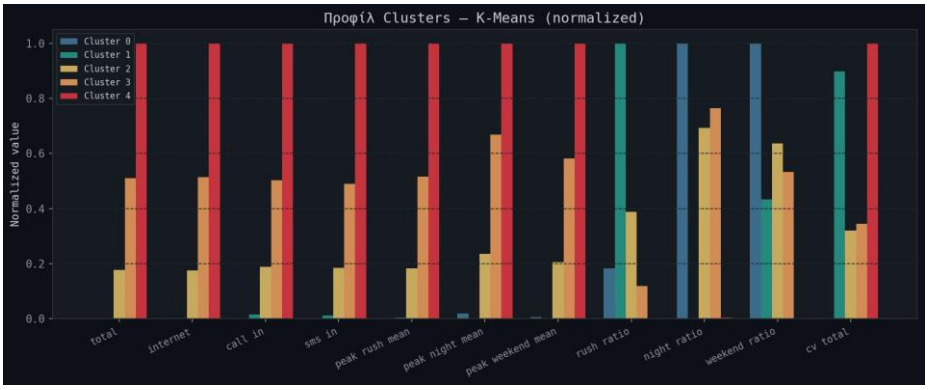
Σχήμα 4α: Silhouette & Davies-Bouldin — K-Means vs Hierarchical.

Σχήμα 4β: Calinski-Harabasz — K-Means vs Hierarchical.

4. Χαρακτηρισμός Clusters

4.1 Προφίλ Clusters — Κανονικοποιημένες Τιμές

Το ραβδόγραμμα κανονικοποιημένων τιμών για 11 χαρακτηριστικά (total, internet, call_in, sms_in, ώρα αιχμής, νύχτα, Σ/Κ, rush_ratio, night_ratio, weekend_ratio, cv_total) αποκαλύπτει σαφείς διαφορές μεταξύ των clusters.

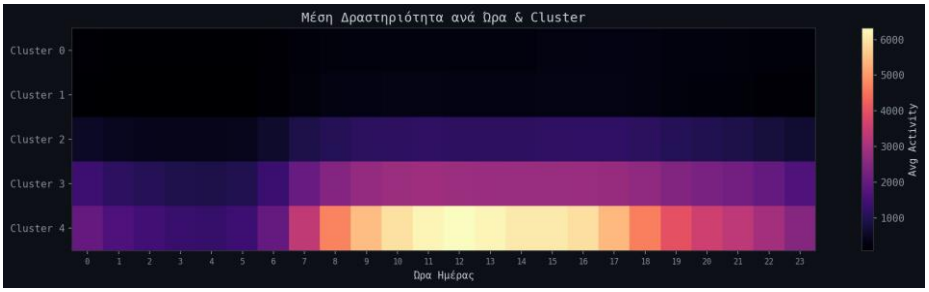


Σχήμα 5: Κανονικοποιημένα Προφίλ Clusters (K-Means). Κάθε μπάρα αντιπροσωπεύει την κανονικοποιημένη μέση τιμή του χαρακτηριστικού για το αντίστοιχο cluster.

4.2 Χωρο-χρονική Ανάλυση

Χρονικό Heatmap

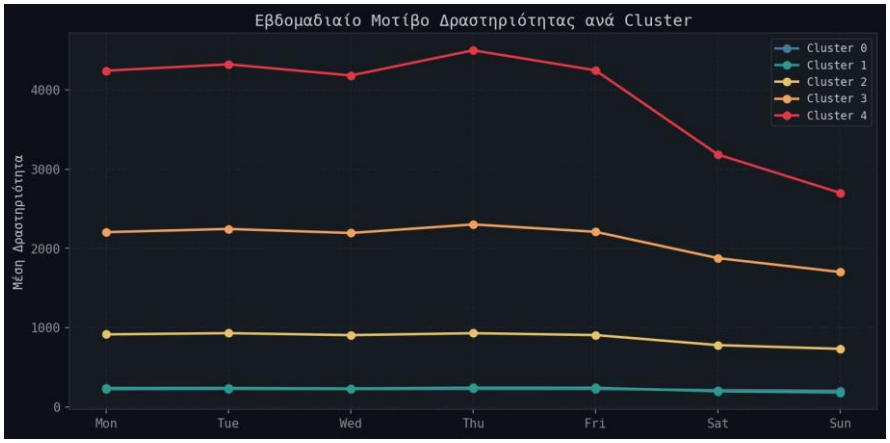
Το heatmap μέσης δραστηριότητας ανά ώρα και cluster αποκαλύπτει ότι το Cluster 4 παρουσιάζει εξαιρετικά έντονη δραστηριότητα (έως 6000+) κατά τις ώρες 8:00-18:00, ενώ τα clusters 0 και 1 παραμένουν σχεδόν ανενεργά όλο το 24ωρο. Τα clusters 2 και 3 παρουσιάζουν ενδιάμεσα επίπεδα δραστηριότητας, με πιο σταθερή κατανομή κατά τη διάρκεια της ημέρας και μικρότερες διακυμάνσεις σε σχέση με το Cluster 4.



Σχήμα 6: Μέση Δραστηριότητα ανά Ώρα & Cluster. Το Cluster 4 κυριαρχεί κατά τις εργάσιμες ώρες.

Εβδομαδιαίο Μοτίβο

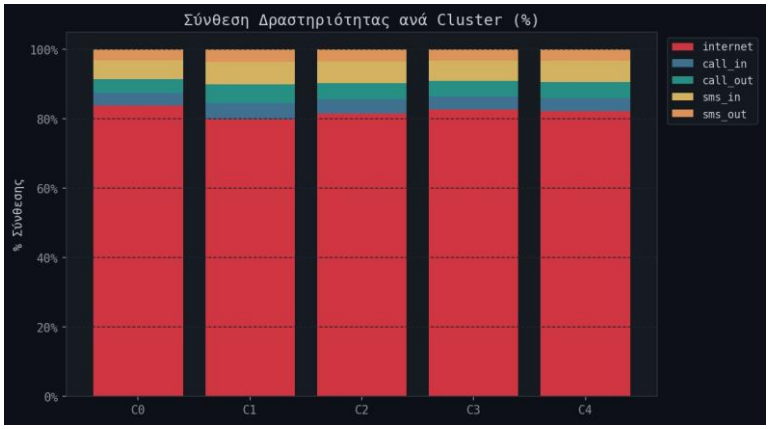
Το εβδομαδιαίο μοτίβο επιβεβαιώνει ότι το Cluster 4 (κόκκινο) έχει σαφώς υψηλότερη δραστηριότητα τις εργάσιμες ημέρες (Δευτ.-Παρ. ~4300-4500) σε σχέση με το Σαββατοκύριακο (~2700), χαρακτηριστικό εμπορικών/αστικών κέντρων.



Σχήμα 7: Εβδομαδιαίο Μοτίβο Δραστηριότητας ανά Cluster. Εμφανής η μείωση στο Σ/Κ για τα clusters υψηλής δραστηριότητας.

Σύνθεση Δραστηριότητας

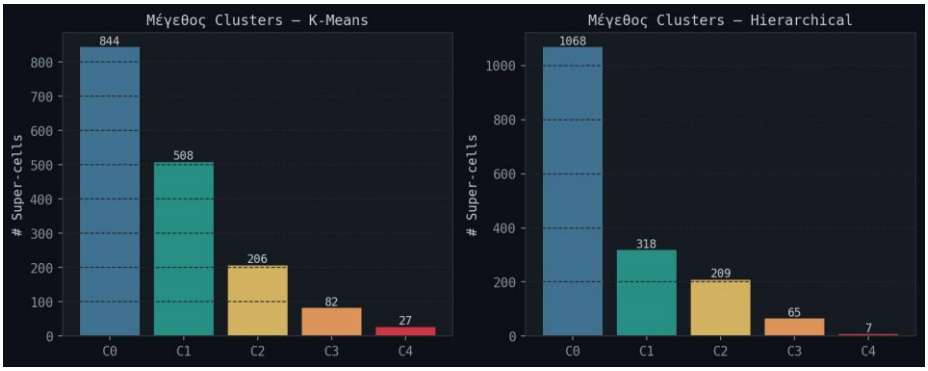
Σε όλα τα clusters, η χρήση διαδικτύου (internet) κυριαρχεί με ποσοστό ~80-82%, ακολουθούμενη από call_out/call_in (~5-10%) και SMS (~8-10%). Οι μικρές διαφορές στη σύνθεση υποδηλώνουν ότι τα clusters διαφέρουν κυρίως ως προς το επίπεδο, όχι το είδος της δραστηριότητας.



Σχήμα 8: Σύνθεση Δραστηριότητας ανά Cluster (%). Το internet αποτελεί τη συντριπτική πλειοψηφία σε όλα τα clusters.

Μεγέθη Clusters

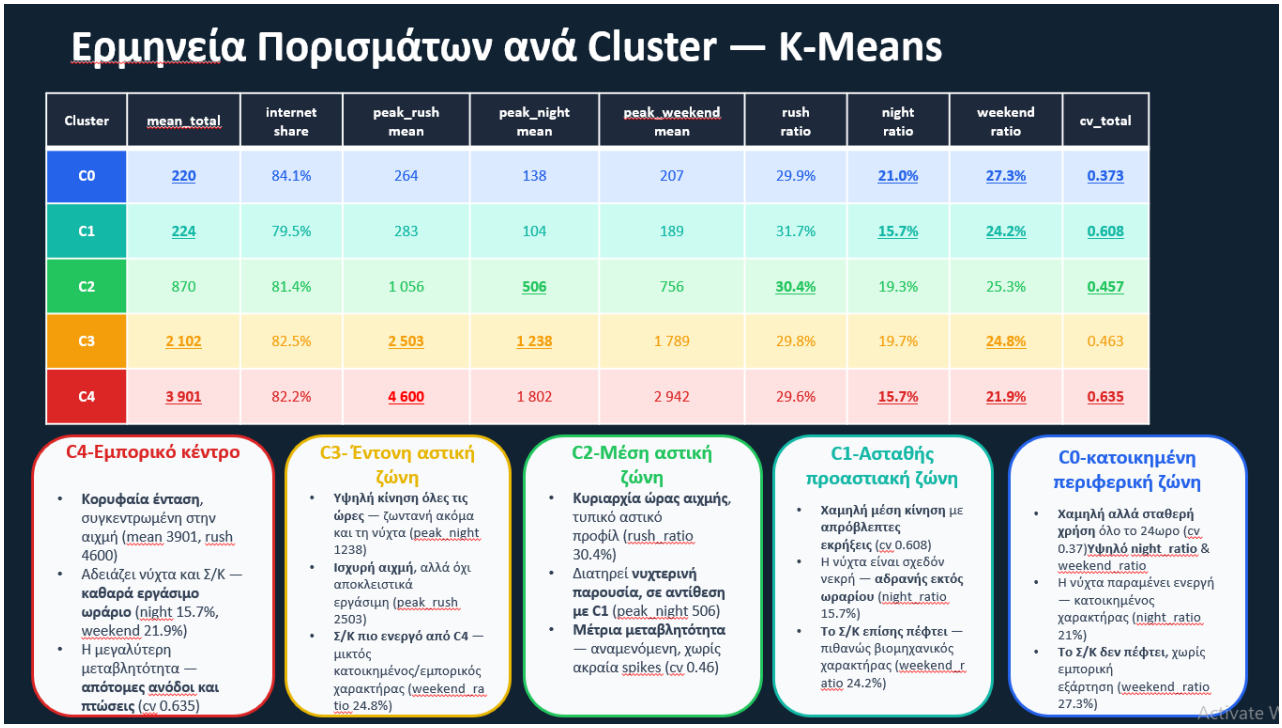
Η κατανομή μεγεθών αντανακλά τη χωρική δομή του Μιλάνου: τα μεγαλύτερα clusters (C0, C1) αντιστοιχούν στις περιφερειακές και αγροτικές ζώνες, ενώ τα μικρότερα (C3, C4) αντιστοιχούν στις εμπορικές και αστικές ζώνες.



Σχήμα 9: Μέγεθος Clusters — K-Means (αριστερά) και Hierarchical (δεξιά).

4.3 Συνοπτικός Πίνακας Χαρακτηρισμού

Στα πλαίσια κάτω από το πινακάκι φαίνεται η ερμηνεία των αποτελεσμάτων. Αξίζει να σημειωθεί ότι τα χρώματα σε αυτό δεν είναι ακριβώς αντιστοιχισμένα με τα χρώματα των cluster στο χάρτη. Αυτό το πινακάκι τυπώνεται στο terminal στο τέλος της εκτέλεσης του κώδικα και το περάσαμε στο power point με τα χρώματα για να είναι πιο ευδιάκριτη η ερμηνεία.



Ερμηνεία Πορισμάτων ανά Cluster — K-Means

Cluster	mean_total	internet share	peak_rush mean	peak_night mean	peak_weekend mean	rush ratio	night ratio	weekend ratio	cv_total
C0	220	84.1%	264	138	207	29.9%	21.0%	27.3%	0.373
C1	224	79.5%	283	104	189	31.7%	15.7%	24.2%	0.608
C2	870	81.4%	1 056	506	756	30.4%	19.3%	25.3%	0.457
C3	2 102	82.5%	2 503	1 238	1 789	29.8%	19.7%	24.8%	0.463
C4	3 901	82.2%	4 600	1 802	2 942	29.6%	15.7%	21.9%	0.635

C4-Εμπορικό κέντρο
- **Κορυφαία ένταση**, συγκεντρωμένη στην αιχμή (mean 3901, rush 4600)
- Αδειάζει νύχτα και Σ/Κ — **καθαρά εργάσιμο ωράριο** (night 15.7%, weekend 21.9%)
- Η μεγαλύτερη μεταβλητότητα — **απότομες ανόδοι και πτώσεις** (cv 0.635)

C3-Έντονη αστική ζώνη
- **Υψηλή κίνηση όλες τις ώρες** — ζωντανή ακόμα και τη νύχτα (peak_night 1238)
- **Ισχυρή αιχμή**, αλλά όχι αποκλειστικά εργάσιμη (peak_rush 2503)
- **Σ/Κ πιο ενεργό από C4** — μικτός κατοικημένος/εμπορικός χαρακτήρας (weekend_ratio 24.8%)

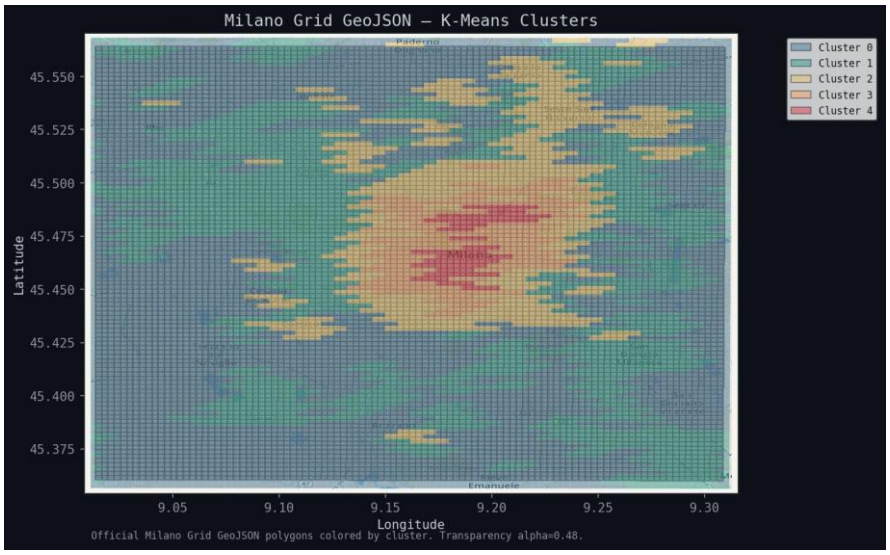
C2-Μέση αστική ζώνη
- **Κυριαρχία ώρας αιχμής**, τυπικό αστικό προφίλ (rush_ratio 30.4%)
- Διατηρεί **νυχτερινή παρουσία, σε αντίθεση με C1** (peak_night 506)
- **Μέτρια μεταβλητότητα** — αναμενόμενη, χωρίς ακραία spikes (cv 0.46)

C1-Ασταθής προαστιακή ζώνη
- **Χαμηλή μέση κίνηση** με **απρόβλεπτες εκρήξεις** (cv 0.608)
- Η νύχτα είναι σχεδόν νεκρή — **αδρανής εκτός ωραρίου** (night_ratio 15.7%)
- **Το Σ/Κ επίσης πέφτει** — πιθανώς βιομηχανικός χαρακτήρας (weekend_ratio 24.2%)

C0-κατοικημένη περιφερική ζώνη
- **Χαμηλή αλλά σταθερή χρήση** όλο το 24ωρο (cv 0.37)**Υψηλό night_ratio** & weekend_ratio
- Η νύχτα παραμένει ενεργή — κατοικημένος χαρακτήρας (night_ratio 21%)
- **Το Σ/Κ δεν πέφτει**, χωρίς εμπορική εξάρτηση (weekend_ratio 27.3%)

5. Χωρική Κατανομή — Χαρτογράφηση

Η απεικόνιση των clusters στον χάρτη του Μιλάνου (GeoJSON polygons) επιβεβαιώνει τη χωρική συνέπεια των αποτελεσμάτων: το Cluster 4 (κόκκινο) καλύπτει αποκλειστικά το κέντρο (περιοχή γύρω από Duomo), ενώ τα clusters 0-1 εκτείνονται στην περιφέρεια. Τα χρώματα των cluster έχουν διαδεχθεί με βάση το mean total του κάθε cluster με τα πιο θερμά χρώματα να σημαίνουν πιο έντονη χρήση.



Σχήμα 10: Χωρική κατανομή clusters στο Μιλάνο (GeoJSON). Σαφής ακτινική δομή από το κέντρο (Cluster 4) προς την περιφέρεια (Clusters 0-1).

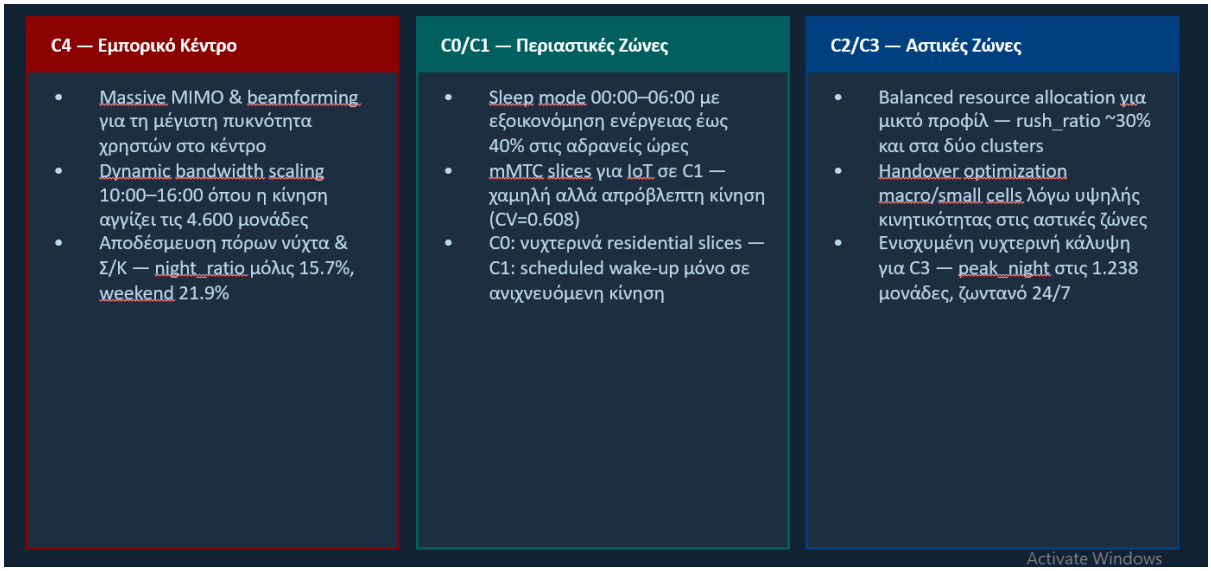
5.1 Dashboard Αποτελεσμάτων

Το dashboard συνοψίζει τις κύριες μετρικές ανά cluster: μέση συνολική δραστηριότητα, internet share, μεταβλητότητα (CV), rush vs. night activity, weekend activity και τις μετρικές αξιολόγησης σε συγκριτικό πίνακα.



Σχήμα 11: Dashboard Clustering (K-Means). Συγκεντρωτική εικόνα όλων των βασικών μετρικών ανά cluster.

5.2 Αξιοποίηση των Clusters στον Σχεδιασμό Δικτύων 5G/6G



Massive MIMO & Beamforming

Massive MIMO: Τεχνική πολλαπλών κεραιών που επιτρέπει την ταυτόχρονη εξυπηρέτηση πολλών χρηστών με υψηλή φασματική απόδοση.

Beamforming: Κατευθυνόμενη εκπομπή σήματος προς συγκεκριμένους χρήστες για βελτίωση κάλυψης και throughput.

- Οι τεχνικές αυτές χρησιμοποιούνται στο C4, καθώς το cluster εμφανίζει τη μεγαλύτερη συγκέντρωση χρηστών και πολύ υψηλή δικτυακή δραστηριότητα.

mMTC

Massive Machine Type Communications (mMTC): Κατηγορία υπηρεσιών 5G σχεδιασμένη για μεγάλο αριθμό IoT συσκευών χαμηλής κατανάλωσης.

- Τα mMTC slices αξιοποιούνται στο C1, επειδή παρουσιάζει χαμηλή αλλά ασταθή δραστηριότητα, χαρακτηριστική περιοχών με IoT επικοινωνία.

Network Slicing

Network Slicing: Δημιουργία εικονικών λογικών δικτύων με διαφορετικά QoS χαρακτηριστικά πάνω στην ίδια υποδομή.

- Χρησιμοποιείται για διαφορετική κατανομή πόρων μεταξύ των clusters, ανάλογα με τη δραστηριότητα και τις απαιτήσεις κάθε περιοχής.

Handover Optimization

Handover Optimization: Βελτιστοποίηση της μετάβασης χρηστών μεταξύ κελιών ώστε να μειώνονται οι αποσυνδέσεις και η καθυστέρηση.

- Είναι ιδιαίτερα σημαντικό στα C2/C3, όπου παρατηρείται αυξημένη κινητικότητα χρηστών σε αστικές περιοχές.

6 Ανταπόκριση σε Feedback και Επίλυση δυσκολίων

Αρχικά στο γράφημα για τα μεγέθη των cluster μας ζητήθηκε στην ενδιάμεση παρουσίαση τα cluster να είναι αντιστοιχημένα 1-1 για να μπορεί να είναι πιο ευδιάκριτη η σύγκριση όπως πλέον είναι στο νέο γράφημα που φαίνεται στο τελευταίο σχήμα του κεφαλαίου 4.2.

Έπειτα μας είχε ζητηθεί να προσθέσουμε το χάρτη του Μιλάνο με τα cluster πάνω να έχουν διαφορετικό χρώμα για να είναι πιο ευδιάκριτα τα αποτελέσματα του clustering. Η υλοποίηση φαίνεται στο κεφάλαιο 5.

Για την δημιουργια των supercell .Αρχικά εξετάστηκε η ομαδοποίηση των grid cells σε super-cells με μορφή 2×3, ώστε κάθε super-cell να διατηρεί χωρική συνέχεια με τους γείτονές του. Ωστόσο, η προσέγγιση αυτή δημιουργούσε προβλήματα στα όρια των γραμμών του πλέγματος, όπου η 2×3 περιοχή δεν ήταν πλήρης. Για λόγους απλότητας επιλέχθηκε τελικά η γραμμική ομαδοποίηση 1×6.

Όσον αφορά την επεξεργασία των δεδομένων. Αρχικά δοκιμάστηκε η επεξεργασία των δεδομένων χωρίς aggregation, φορτώνοντας απευθείας όλες τις εγγραφές — κάτι που αποδείχθηκε αδύνατο λόγω του τεράστιου όγκου δεδομένων (62 ημέρες × 10.000 cells), με αποτέλεσμα εξάντληση μνήμης. Στη συνέχεια δοκιμάστηκε η προσέγγιση load πρώτα**,** aggregation μετά, όπου φορτώνονταν όλα τα αρχεία στη μνήμη και στη συνέχεια γινόταν η επεξεργασία , με αποτέλεσμα εξαιρετικά μεγάλους χρόνους εκτέλεσης. Τελικά υλοποιήθηκε η chunk-based προσέγγιση, όπου κάθε αρχείο διαβάζεται και συγκεντρώνεται τμηματικά, διατηρώντας τη μνήμη σε διαχειρίσιμα επίπεδα και μειώνοντας σημαντικά τον χρόνο εκτέλεσης.

Επίσης με τη χωρική ανάλυση ενός λεπτού που αναφέρθηκε στην παρουσίαση αυτό που είχαμε σκεφτεί ήταν ότι κάθε super-cell αντιστοιχεί σε ομαδοποίηση 6 grid cells, ενώ τα δεδομένα έχουν προηγουμένως συγκεντρωθεί (aggregation) ανά 10 δευτερόλεπτα. Επομένως, κατά την επεξεργασία ενός super-cell αναλύεται πρακτικά η συνολική δραστηριότητα ενός μικρού χωρικού τμήματος για χρονικό παράθυρο περίπου ενός λεπτού.

7. Συμπεράσματα

Η εφαρμογή τεχνικών clustering στο Milan Telecom Dataset οδήγησε στον εντοπισμό πέντε διακριτών προφίλ δικτυακής δραστηριότητας, τα οποία αντιστοιχούν σε διαφορετικούς τύπους αστικών και περιαστικών περιοχών.

- **Cluster 0 (Κατοικημένη Περιφερική Ζώνη — 844 super-cells):**
  Χαμηλή αλλά σταθερή δραστηριότητα σε όλο το 24ωρο, με αυξημένη νυχτερινή και weekend παρουσία, χαρακτηριστική κατοικημένων περιοχών.
- **Cluster 1 (Ασταθής Προαστιακή Ζώνη — 508 super-cells):**
  Χαμηλή μέση δραστηριότητα αλλά αυξημένη μεταβλητότητα (CV=0.608), υποδηλώνοντας περιοχές με ασταθή ή σποραδική χρήση δικτύου.
- **Cluster 2 (Μέση Αστική Ζώνη — 206 super-cells):**
  Μέτρια συνολική δραστηριότητα με κυριαρχία ωρών αιχμής και περιορισμένη νυχτερινή παρουσία, αντιπροσωπεύοντας τυπικές αστικές περιοχές.

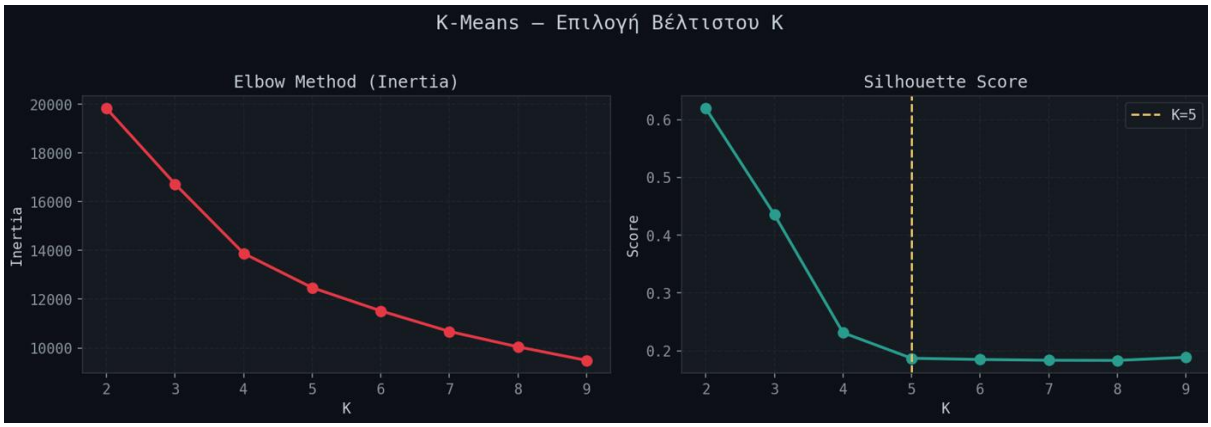
- **Cluster 3 (Έντονη Αστική Ζώνη — 82 super-cells):**
  Υψηλή δραστηριότητα κατά τη διάρκεια της ημέρας αλλά και σημαντική νυχτερινή κίνηση, χαρακτηριστική μικτών αστικών και εμπορικών περιοχών.
- **Cluster 4 (Κεντρικό Εμπορικό Κέντρο — 27 super-cells):**
  Η περιοχή με τη μεγαλύτερη συνολική δραστηριότητα και έντονο ημερήσιο μοτίβο, που αντιστοιχεί στο εμπορικό κέντρο του Μιλάνου.

Από τη σύγκριση των αλγορίθμων προέκυψε ότι το Hierarchical Clustering (Ward) εμφανίζει ελαφρώς καλύτερες επιδόσεις στις μετρικές Silhouette και Davies–Bouldin, ενώ ο K-Means παρουσιάζει υψηλότερο Calinski–Harabasz score και καλύτερη γεωμετρική οργάνωση των clusters στην PCA προβολή.

Η χωρική κατανομή των clusters επιβεβαιώνει τη χαρακτηριστική ακτινική δομή του Μιλάνου, με το εμπορικό κέντρο να συγκεντρώνει τη μεγαλύτερη δραστηριότητα και τις περιφερειακές περιοχές να εμφανίζουν χαμηλότερη και πιο σταθερή χρήση δικτύου. Τα αποτελέσματα μπορούν να αξιοποιηθούν σε εφαρμογές network slicing, δυναμικής κατανομής πόρων και βελτιστοποίησης κάλυψης σε δίκτυα 5G/6G.

8. Επέκταση του κώδικα με χωρικό feature και σύγκριση αποτελεσμάτων (extra)

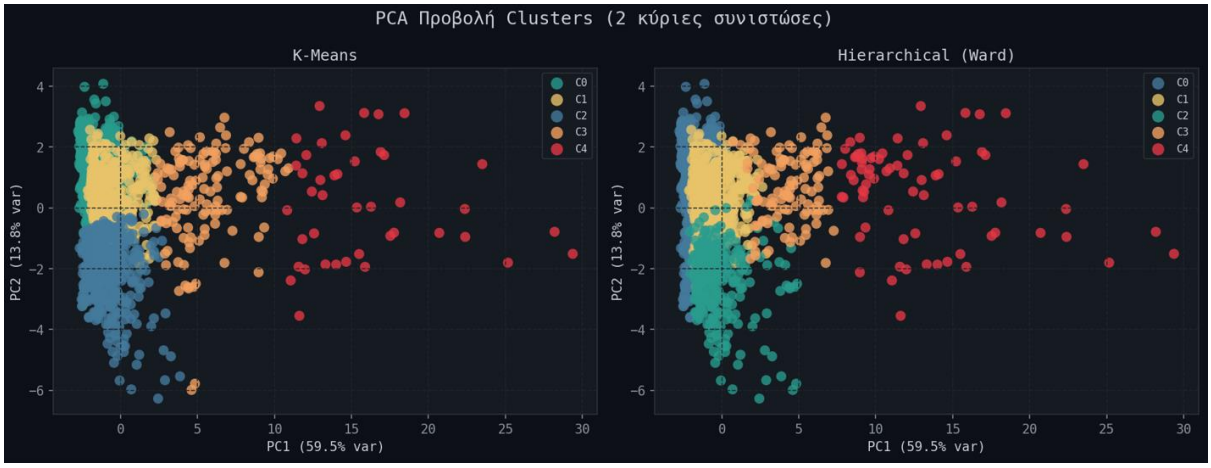
Στην αρχή επιλέχθηκε K=5 αλλά με το καινούριο feature φαίνεται ότι το K=4 είναι καλύτερο. Η σύγκριση όμως θα γίνει με K=5 για να γίνει πιο καθαρή σύγκριση.



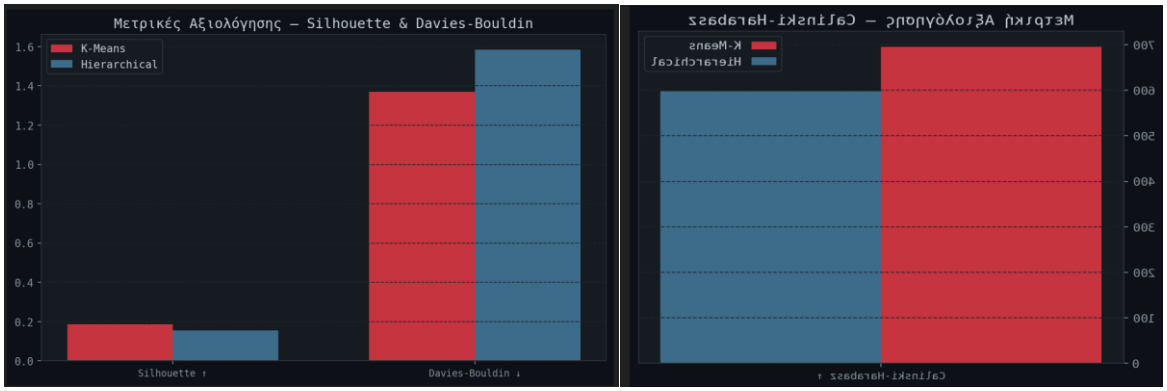
Στο Elbow Method φαίνεται καθαρά ότι μέχρι το K=4 η inertia πέφτει πολύ έντονα, ενώ μετά η βελτίωση γίνεται πιο μικρή.

Τα αποτελέσματα λόγο της επιλογής K=5 που έχει αρκετά μικρό silhouette score φαίνονται αρκετά χειρότερα όπως θα το περιμέναμε.

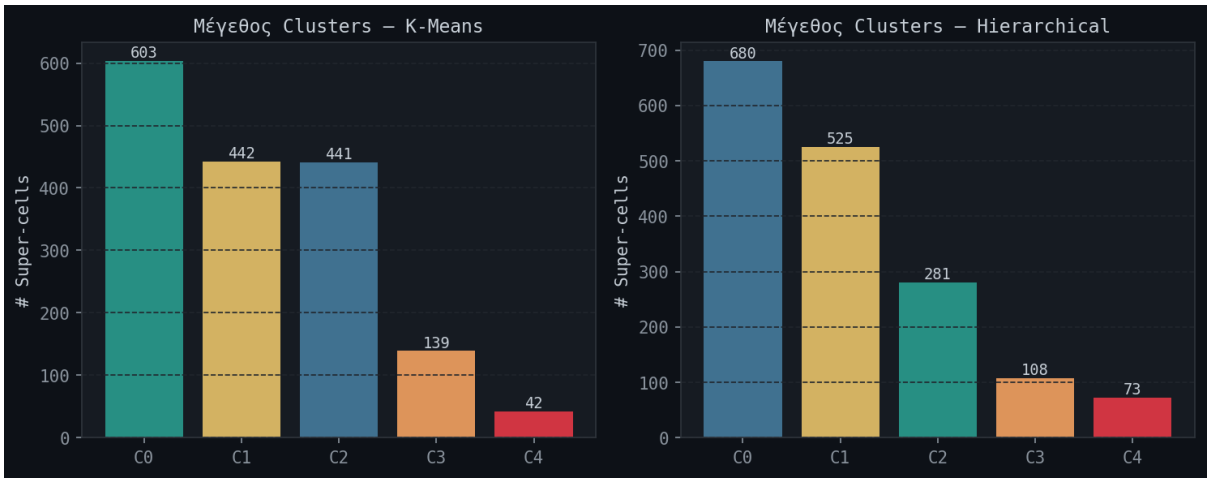
Αυτό φαίνεται καθαρά στο PCA οπού βλέπουμε πολύ έντονο μπλέξιμο μεταξύ clusters:



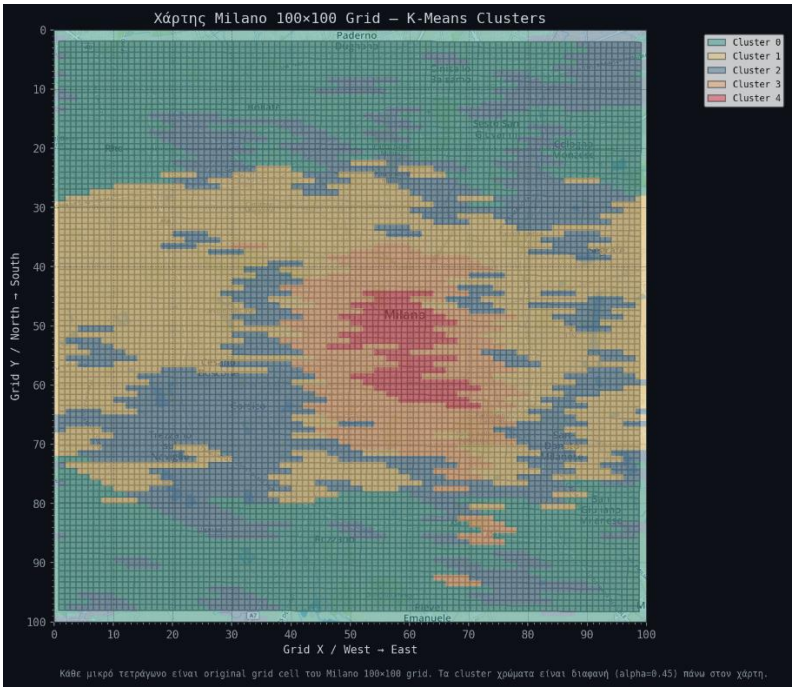
Παρόλα αυτά εξακολουθεί ο k-means να φαίνεται καλύτερη επιλογή με καλύτερο silhouette και Calinski-Hazard score από τον hierarchical.



Παρόλα αυτά αξίζει να σημειωθεί ότι υπάρχει πιο ισορροπημένη κατανομή των supercell στα cluster.



Και φαίνονται πιο καλά ενωμένα στη χωρική απεικόνιση.



Οι Υπόλοιπες απεικονίσεις που αφορούν τη χρήση στο κάθε cluster είναι αρκετά παρόμοιες με αυτές που εξετάσαμε στον αρχικό κώδικα.

9. Βιβλιογραφία

[1] Harvard Dataverse — Milan Telecom Dataset (ODbL License): https://doi.org/10.7910/DVN/EGZHFV

[2] Ahmed, M., Seraj, R., & Islam, S.M.S. (2020). *The K-means algorithm: A comprehensive survey and performance evaluation.* Electronics, 9(8), 1295. https://www.mdpi.com/2079-9292/9/8/1295

[3] Sinaga, K.P. & Yang, M.S. (2020). *Unsupervised K-means clustering algorithm.* IEEE Access, 8, 80716–80727. https://ieeexplore.ieee.org/document/9075143

[4] Murtagh, F. & Legendre, P. (2014). *Ward's Hierarchical Agglomerative Clustering Method: Which Algorithms Implement Ward's Criterion?* Journal of Classification, 31, 274–295. https://link.springer.com/article/10.1007/s00357-014-9161-z

[5] Sharma, S. & Batra, N. (2019). *Comparative Study of Single Linkage, Complete Linkage, and Ward Method of Agglomerative Clustering.* IEEE COMITCon. https://ieeexplore.ieee.org/abstract/document/8862232

[6] Murtagh, F. & Contreras, P. (2022). *Comprehensive survey on hierarchical clustering algorithms and recent developments.* Artificial Intelligence Review. https://link.springer.com/article/10.1007/s10462-022-10366-3

[7] Chicco, D. et al. (2025). *The Silhouette coefficient and the Davies-Bouldin index are more informative than Dunn index, Calinski-Harabasz index...* PeerJ Computer Science, 11:e3309. https://peerj.com/articles/cs-3309/

[8] Gagolewski, M. et al. (2021). *Are cluster validity measures (in)valid?* Information Sciences, 581, 620–636. https://www.sciencedirect.com/science/article/abs/pii/S0020025521010082

[9] Ringnér, M. (2008). *What is principal component analysis?* Nature Biotechnology, 26, 303–304. https://www.nature.com/articles/nbt0308-303

[10] Jolliffe, I.T. & Cadima, J. (2016). *Principal component analysis: a review and recent developments.* Phil. Trans. R. Soc. A, 374: 20150202. https://royalsocietypublishing.org/doi/10.1098/rsta.2015.0202

[11] Elsayed, M. & Erol-Kantarci, M. (2021). *Radio Resource and Beam Management in 5G mmWave Using Clustering and Deep Reinforcement Learning.* arXiv. https://arxiv.org/pdf/2103.05047

[12] Barakabitze, A.A. et al. (2020). *5G network slicing using SDN and NFV: A survey of taxonomy, architectures and future challenges.* arXiv. https://arxiv.org/pdf/1912.02802

[13] *Advanced Clustering for Mobile Network Optimization: A Systematic Literature Review.* (2025). PMC. https://www.ncbi.nlm.nih.gov/pmc/articles/PMC12694655/

[14] Li, K. et al. (2021). *Coordination of Macro Base Stations for 5G Network with User Clustering.* Sensors, 21(16), 5501. https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8401326/

[15] Cremaschi, A. et al. (2023). *A change-point random partition model for large spatio-temporal datasets.* arXiv. https://arxiv.org/pdf/2312.12396

[16] Louvrier et al. (2017). *Analysis of the communities of an urban mobile phone network.* PLOS ONE. https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5363903/